Informe técnico — Predicción de compra de boletos turísticos

1. Introducción

En el presente trabajo se desarrolló un modelo de Machine Learning predictivo orientado a estimar la probabilidad de que un cliente compre un boleto turístico en el próximo mes, a partir de su comportamiento histórico y características asociadas al usuario. El objetivo central fue optimizar la gestión de los recursos económicos, humanos y de marketing, dirigiendo las campañas promocionales hacia aquellos clientes con mayor probabilidad real de compra. Logrando una reducción de costos reales que contribuye a un aumento en las utilidades netas de la compañía.

En el contexto actual, sobre todo después de la pandemia Covid-19, las empresas del sector turístico enfrentan un entorno competitivo y con presupuestos publicitarios limitados. Debido a esto, es fundamental identificar de manera anticipada a los clientes potenciales para mejorar la eficiencia comercial y aumentar la tasa de conversión de las campañas.

El trabajo combina técnicas de ciencia de datos y aprendizaje automático supervisado, aplicadas a la base de datos de clientes para la toma de decisiones futuras. Se buscaron respuestas a preguntas clave como:

- ¿Qué tipo de cliente tiene mayor probabilidad de comprar un boleto el próximo mes?
- ¿Cuáles son las variables que más influyen en esa decisión?
- ¿Cómo podemos reducir la inversión en campañas de marketing incrementando las oportunidades de venta?

2. Preparación y análisis de los datos

Se partió de una base de datos de clientes de una empresa turística que contenía información personal, comportamiento de compra, historial de contacto y variables relacionadas con su actividad reciente en la página de la firma.

2.1 Limpieza y preprocesamiento

Antes de construir los modelos predictivos, se realizó un minucioso Análisis Exploratorio de Datos (EDA) que consistió en:

- Eliminación de valores faltantes y estandarización de variables categóricas mediante one-hot encoding.
- Normalización de variables numéricas para garantizar comparabilidad entre magnitudes.
- Revisión de outliers y detección de registros inconsistentes.
- Creación y modificación de variables (por ejemplo, tiempo desde la última compra) para capturar mejor el comportamiento del cliente.

2.2 Balanceo de clases

Durante el análisis exploratorio se observó un fuerte desbalance de clases en la variable objetivo (Compra = Sí / No), con una proporción de clientes que efectivamente compran (16%) mucho menor a los que no lo hacen (84%). Para evitar que los modelos se vieran sesgados hacia la clase mayoritaria, se aplicaron dos estrategias complementarias:

- Ponderación de clases mediante el parámetro class_weight o scale_pos_weight, según el modelo.
- Validación cruzada estratificada para mantener la proporción real de clases en cada partición de entrenamiento.

2.3 División del conjunto de datos

Los datos fueron divididos en dos subconjuntos: un 70% para entrenamiento, utilizado para ajustar los mejores parámetros e hiperparámetros de los modelos, y un 30% de prueba, para evaluar el desempeño del modelo sobre datos no vistos. Esta división permitió validar la capacidad de generalización del modelo, es decir, su rendimiento al predecir el comportamiento de nuevos usuarios.

3. Modelado y evaluación

El enfoque utilizado corresponde al de una clasificación supervisada binaria, donde la variable objetivo indica si un cliente comprará (1) o no (0) un boleto en el próximo mes.

3.1 Modelos evaluados

Se entrenaron y compararon distintos algoritmos de complejidad creciente:

- **Modelo Baseline:** Funcionó como punto de partida para comprar el resto de los modelos, pero desde una perspectiva comercial, ya que su recall para la clase 'Yes' fue 0.
- **Regresión Logística Balanceada**: Modelo con problema de subajuste: no logra capturar la suficiente complejidad en los patrones de compra.
- **Árbol de Decisión:** Se incorporaron relaciones no lineales y reglas interpretables del tipo "si-entonces". Con una profundidad máxima de 13, mostró un equilibrio razonable entre ajuste y generalización.
- **Random Forest:** mejoró la estabilidad y precisión respecto a un único árbol, reduciendo el sobreajuste. Con una profundidad de 12 logró un desempeño sólido y resistente.
- **XGBoost:** combina múltiples árboles de forma secuencial, corrigiendo los errores del modelo anterior. Se destacó por su excelente rendimiento y capacidad para manejar el desbalance de clases, confirmando su estabilidad a través de la validación cruzada con un F1–score de 0.96 demostrando que el alto rendimiento no se debe a un sobreajuste.
- **LightGBM:** variante optimizada para grandes volúmenes de datos, con un entrenamiento más rápido, presentando métricas muy sólidas en la prueba, alcanzando un F1-Score de 0.941.

3.2 Métricas de evaluación

Para comparar los modelos, se utilizaron las siguientes métricas:

- Accuracy: proporción total de aciertos.
- Precisión (Sí): porcentaje de clientes predichos como compradores que efectivamente compran.
- Recall (Sí): porcentaje de compradores reales que el modelo logra identificar.

- F1-score: media armónica entre precisión y recall.
- AUC: capacidad del modelo para distinguir entre compradores y no compradores.

Dado que el objetivo del negocio es invertir en los clientes con probabilidad real de compra, se prioriza la métrica Precisión tratando de no perder sensibilidad y, en términos de rendimiento general para clases desbalanceadas, el F1-Score. Es decir, buscamos minimizar los falsos positivos: aquellos clientes a los que se destina presupuesto publicitario, pero que finalmente no compran.

3.3 Resultados comparativos

Modelo	Accuracy	Precisión	Recall	F1-score	AUC
Baseline	0.840	0.000	0.000	0.000	0.500
Regresión Logística Balanceada	0.723	0.330	0.680	0.440	0.710
Árbol de Decisión	0.951	0.806	0.918	0.858	0.938
Random Forest	0.970	0.956	0.855	0.930	0.928
XGBoost	**0.993**	**0.992**	**0.963**	**0.977**	**1.000**
LightGBM 2	0.980	0.915	0.968	0.941	0.998

Tabla 1: Métricas de evaluación de rendimiento de los modelos utilizados para la predicción.

En la tabla 1 se presenta un resumen de los resultados de las métricas de evaluación de desempeño de los modelos probados para la predicción de compra. El modelo de Regresión Logística balanceado alcanzó un F1-Score de 0.44, indicando underfitting, a pesar de usar balanceo de clases y optimización de hiperparámetros. En contraste, los modelos Random Forest y Árbol de Decisión mejoraron sustancialmente la detección de la clase minoritaria, alcanzando F1-scores de 0.930 y 0.858, respectivamente.

No obstante, el XGBoost se posiciona como el claro vencedor con un F1-Score de Validación Cruzada promedio de (0.961 ± 0.003). Esta métrica confirma su capacidad para mantener un equilibrio entre la Precisión (0.992 - minimizando los Falsos Positivos) y el Recall (0.963 - maximizando la detección de compradores), demostrando su capacidad para identificar correctamente a los clientes con intención real de compra, lo cual asegura la optimización estratégica y económica de los recursos de la compañía.

	Predicho: No compra (0)	Predicho: Compra (1)
Real: No compra (0)	1970	3
Real: Compra (1)	14	365

Tabla 2: Matriz de confusión del grupo Test para el modelo XGBoost luego de una validación cruzada.

3.4 Ajuste del umbral de decisión

Una de las ventajas del modelo es que no se limita a una decisión binaria ("Sí compra / No compra"), sino que asigna una probabilidad de compra a cada cliente, lo que permite ajustar el umbral de corte según los objetivos del negocio:

- Si se desea minimizar el gasto en campañas (evitar falsos positivos), se puede subir el umbral (por ejemplo, de 0.5 a 0.7), para priorizar la precisión.
- Si se busca no perder potenciales compradores, se puede bajar el umbral, aumentando el recall.

En este caso, se seleccionó un threshold de 0.35, ya que logra un equilibrio adecuado entre precisión y recall, reduciendo así el gasto en campañas ineficientes sin sacrificar de manera significativa el volumen de ventas potenciales. Este trade-off es fundamental en la práctica, ya que permite priorizar la inversión donde genera mayor retorno.

Tras aplicar el nuevo umbral, el desempeño del modelo puede observarse en Tabla 3, donde se presentan las métricas de evaluación, así como la matriz de confusión (Figura 1) y en la curva ROC (Figura 2). Estas visualizaciones permiten apreciar de forma clara el equilibrio logrado entre precisión y recall, y la elevada capacidad discriminativa del modelo bajo threshold seleccionado.

Métrica	Accuracy	Precision	Recall	F1-score	AUC-ROC
Valor	0.994473	0.984127	0.981530	0.982827	1.000

Tabla 3: Métricas de evaluación de desempeño del modelo XGBoost luego de la optimización de las mismas al modificar el threshold (0.35).

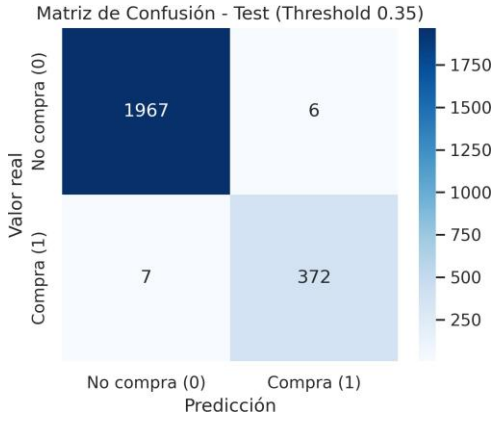


Figura 2

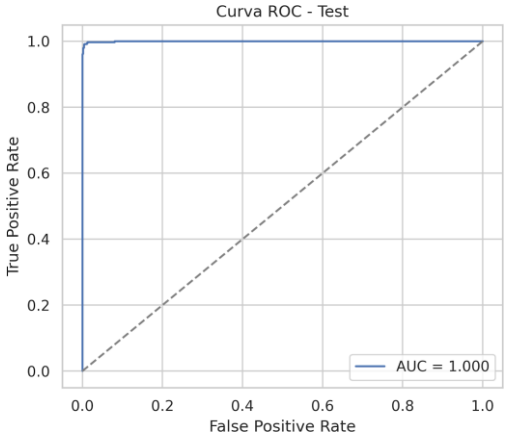


Figura 3

Figura 1: Matriz de confusión del reentrenamiento del modelo con Threshold = 0.35.

Figura 2: Curva ROC- Test del reentrenamiento del modelo XGBoost luego de modificar el threshold a un valor de 0.35.

4. Aplicación práctica del modelo y aporte al negocio

4.1 Toma de acción a partir de la predicción

El modelo predictivo desarrollado no busca reemplazar la estrategia comercial de la empresa, sino potenciar con inteligencia basada en datos. A partir de la información histórica de clientes y el entrenamiento con distintos algoritmos, se puede estimar la probabilidad de que una persona compre un boleto en el próximo mes, permitiendo que el área de marketing pueda dirigir sus campañas publicitarias de manera más eficiente. De esta forma, los recursos (tiempo, dinero, comunicación personalizada) se destinan a los segmentos que potencialmente podrían generar mayor retorno.

En la práctica, esto podría traducirse en dos tipos de acciones:

- Segmentación inteligente: se tiene en cuenta únicamente a los clientes que tienen probabilidad de compra y se segmentan en función de su probabilidad: Baja (0,35 - 0,50); Media (0,50 - 0,75) y Alta (mayor a 0,75).
- Campañas dirigidas y optimización del presupuesto:
    - Probabilidad Alta: este segmento presenta alta probabilidad de compra, lo que indica que, muchos de estos clientes probablemente concretaría la compra, aun sin intervención. Por este motivo, se les asigna una proporción menor del presupuesto total, las acciones se centran en programas de fidelización, acceso exclusivo a nuevos productos, productos premium o suscripciones y programas de referidos. La inversión busca maximizar el valor a largo plazo del cliente.
    - Probabilidad Intermedia: estos clientes pueden decidir por comprar o no, por lo que se justifica destinar una mayor parte del presupuesto de marketing, ya que con los estímulos adecuados se puede aumentar significativamente su probabilidad de conversión. Se les envían ofertas por tiempo limitado o descuentos claros sobre los productos que hayan mostrado interés. Además, se realizan pruebas para determinar si un enfoque centrado en el beneficio o en el precio genera un mayor retorno, con el fin de optimizar la tasa de conversión.
    - Probabilidad Baja: las probabilidades de compra son reducidas, por lo que es menos probable que una inversión publicitaria significativa logre modificar su decisión. Por lo tanto, se asigna un presupuesto acotado o nulo. Se identifican las barreras de este segmento a través de encuestas breves. En lugar de buscar una venta directa, se prioriza contenido que aporte valor, como guías y tutoriales que resuelvan problemas.

Impacto Económico de la Segmentación Predictiva

Para ilustrar el efecto práctico de la segmentación basada en probabilidades de compra, se presenta una “campaña de juguete” que compara una campaña tradicional con una campaña optimizada mediante el modelo predictivo. Todas las variables permanecen constantes, excepto el costo de marketing aplicado a cada segmento.

Campaña sin Modelo Predictivo

- Ticket promedio de venta: $1.000
- Costo de marketing por cliente: 10% del ticket = $100
- Total de clientes contactados: 70.000
- Probabilidad promedio de compra: 0,160714
- Compradores esperados: 70.000 × 0,160714 ≈ 11.250
- Ventas totales: 11.250 × 1.000 = $11.250.000
- Costo total: 70.000 × 100 = $7.000.000
- Resultado: 11.250.000 − 7.000.000 = $4.250.000
- ROI: (4.250.000 / 7.000.000) × 100 = 60,71%

Campaña con Modelo Predictivo

- Ticket promedio de venta: $1.000
- Costo de marketing según probabilidad: Alta (10% → $100), Media (15% → $150) y Baja (5% → $50).

Bajo un escenario idealizado donde el modelo identifica correctamente a los 11.250 compradores (solo para fines ilustrativos), la distribución estimada sería:

- Alta probabilidad (88,88%): 11.250 × 0,8888 ≈ 10.000,
- Media probabilidad (8,46%): ≈ 952,
- Baja probabilidad (2,66%): ≈ 298.

- Ventas totales: 11.250 × 1.000 = $11.250.000
- Costos por segmento:
  - Alta: 10.000 × 100 = $1.000.000
  - Media: 952 × 150 = $142.800
  - Baja: 298 × 50 = $14.900

- Costo total: $1.157.700
- Resultado: 11.250.000 − 1.157.700 = $10.092.300
- ROI: (10.092.300 / 1.157.700) × 100 = 871,90%

Impacto Económico

- Ahorro de costos: 7.000.000 − 1.157.700 = $5.842.300
- Incremento en ganancias: (10.092.300 / 4.250.000 − 1) × 100 = 137,47%

Este análisis muestra que una campaña de marketing dirigida exclusivamente a los segmentos con mayor probabilidad de compra reduce drásticamente los costos operativos e incrementa significativamente los márgenes de ganancia. Incluso bajo un modelo simplificado, el impacto del enfoque predictivo es marcado y evidencia el valor económico de una estrategia basada en datos.

Nota: Se trata de un caso ilustrativo con valores de demostración, no correspondientes a datos reales de la empresa.

4.2 Interpretación del modelo

El modelo seleccionado (XGBoost) no solo ofrece gran precisión, sino también la posibilidad de interpretar qué variables influyen más en la decisión de compra.

Entre las características más relevantes que el modelo identificó se destacan:

- La frecuencia de compra previa y el tiempo desde la última compra: los clientes que compraron recientemente tienen más probabilidad de volver a hacerlo.
- Las interacciones con campañas anteriores (por ejemplo, haber calificado vuelos anteriores y el promedio anual de vistas en la página web).
- El tipo de destino preferido (nacional/internacional) y estacionalidad: ciertos perfiles muestran patrones más predecibles según la época del año.
- Variables sociodemográficas (edad, ingresos, grupo familiar) con influencia moderada pero consistente.

Estos resultados permiten no solo predecir, sino también entender el comportamiento del cliente.

Así, la empresa podría diseñar mensajes más personalizados, adaptar los descuentos o incluso planificar la oferta de productos según la demanda esperada.

4.3 Impacto potencial

La adopción de este modelo en un entorno real podría tener un impacto significativo en tres dimensiones:

Eficiencia comercial: maximiza el retorno sobre inversión de las campañas, al reducir gastos en clientes con baja probabilidad de compra y enfocándose en los clientes de probabilidad media - alta. Se puede integrar en los sistemas actuales de CRM o marketing digital, actualizándose mensualmente.

Toma de decisiones basada en datos: permite al equipo de marketing pasar de la intuición a hacerlo sobre evidencia cuantitativa dada por las probabilidades de compra predichas por el modelo, midiendo la efectividad de cada campaña y ajustando estrategias en tiempo real.

Valor agregado al negocio: Fortalece el vínculo entre áreas técnicas y comerciales, permitiendo construir una base sólida para futuros desarrollos de analítica predictiva. Por ende, este modelo no solo predice, sino que orienta las decisiones de negocio hacia el uso más eficiente de los recursos.

4.5 Limitaciones y oportunidades de mejora

Como todo modelo predictivo, este tiene algunas limitaciones que es importante reconocer:

- Dependencia de la calidad de los datos: si los registros futuros cambian su estructura, el modelo deberá entrenarse nuevamente.
- Posible sesgo temporal: Sería ideal incorporar datos de varias temporadas o años para mejorar la robustez.
- Simplificación del comportamiento humano: aunque los modelos capturan patrones, la decisión final de compra también depende de factores externos (economía, clima, promociones de la competencia, etc.).

A futuro, podrían incorporarse mejoras como:

- Uso de modelos de aprendizaje profundo o series temporales para capturar tendencias a largo plazo.

- Integración con herramientas de marketing automatizado para ejecutar campañas directamente según las predicciones.

5. Conclusiones

El desarrollo de este modelo predictivo permite transformar datos históricos en conocimiento accionable, aportando una solución concreta a un problema habitual en el sector turístico: cómo invertir mejor los recursos de marketing para generar ventas reales.

Tras ajustar el umbral de decisión, el modelo XGBoost demostró el mejor rendimiento general, alcanzando métricas sólidas y demostrando una excelente capacidad discriminativa y un buen equilibrio entre identificar compradores y minimizar errores.

Esto brinda a la empresa una herramienta práctica para dirigir esfuerzos hacia los clientes correctos, reducir gastos en campañas poco efectivas y planificar estrategias comerciales basadas en evidencia y no en suposiciones.

Si se incorporan más períodos de datos y nuevas variables, el desempeño podría mejorar aún más, fortaleciendo su utilidad para decisiones comerciales basadas en datos.

En resumen, este trabajo muestra cómo la ciencia de datos puede aportar valor tangible al negocio, conectando la analítica avanzada con la toma de decisiones estratégicas. El modelo propuesto constituye una base sólida sobre la cual seguir construyendo soluciones predictivas orientadas a la eficiencia y al crecimiento.